

§3.4 一致最小方差无偏估计—优化准则

均方误差准则

设 $\mathcal{F} = \{p(x; \theta) : \theta \in \Theta\}$ 是参数分布族, $g(\theta)$ 是待估参数.

$\tilde{X} = (X_1, X_2, \dots, X_n)$ 是取自 $p(x; \theta)$ 的一个样本.

Definition

定义3.4.1 设 $\hat{g} = \hat{g}(\tilde{X})$ 是 $g(\theta)$ 的一个估计量, 称

$$E_{\theta}(\hat{g} - g(\theta))^2$$

为 \hat{g} 的均方误差(mean squared error).

若有 $g(\theta)$ 的两个估计量, \hat{g}_1 和 \hat{g}_2 , 满足

$$E_{\theta}(\hat{g}_1 - g(\theta))^2 \leq E_{\theta}(\hat{g}_2 - g(\theta))^2, \quad \forall \theta \in \Theta,$$

则称在均方误差(MSE)准则下, \hat{g}_2 不优于 \hat{g}_1 (或称 \hat{g}_1 不劣于 \hat{g}_2).

若上式中的不等号至少对某一个 $\theta \in \Theta$ 成立, 则称 \hat{g}_1 优于 \hat{g}_2 .

Example

设 X_1, X_2, \dots, X_n 是取自正态总体 $N(\mu, \sigma^2)$ 的样本, $n \geq 2$.

$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 和 $S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ 都是 σ^2 的估计. 前者是无偏估计. 计算它们的均方误差.

因为 $(n-1)S^2/\sigma^2 \sim \chi^2(n-1)$, 由 $\chi^2(n)$ 的定义知, 若 Y_i 为i.i.d.正态 $N(0, 1)$ 变量($i = 1, 2, \dots, n-1$), 则 $\sum_{i=1}^{n-1} Y_i^2 \sim \chi^2(n-1)$. 所以

$$\begin{aligned}\text{Var}\{S^2\} &= \text{Var}\left\{\frac{\sigma^2}{n-1} \frac{(n-1)S^2}{\sigma^2}\right\} = \frac{\sigma^4}{(n-1)^2} \text{Var}\left\{\sum_{i=1}^{n-1} Y_i^2\right\} \\ &= \frac{\sigma^4}{n-1} \text{Var}(Y_1^2) = \frac{\sigma^4}{n-1} [\text{E}Y_1^4 - (\text{E}Y_1^2)^2] = \frac{2\sigma^4}{n-1}.\end{aligned}$$

所以 S^2 的均方误差为

$$\text{E}\{S^2 - \sigma^2\}^2 = \text{Var}\{S^2\} = \frac{2\sigma^4}{n-1}.$$

而 $S_n^2 = \frac{n-1}{n}S^2$, 所以

$$ES_n^2 = \frac{n-1}{n}ES^2 = \frac{n-1}{n}\sigma^2.$$

S_n^2 的均方误差为

$$\begin{aligned} E\{S_n^2 - \sigma^2\}^2 &= \text{Var}\{S_n^2\} + (ES_n^2 - \sigma^2)^2 \\ &= \left(\frac{n-1}{n}\right)^2 \text{Var}\{S^2\} + \left(-\frac{1}{n}\sigma^2\right)^2 \\ &= \left(\frac{n-1}{n}\right)^2 \frac{2\sigma^4}{n-1} + \frac{\sigma^4}{n^2} = \frac{2n-1}{n^2}\sigma^4. \end{aligned}$$

$$E\{S_n^2 - \sigma^2\}^2 < E\{S^2 - \sigma^2\}^2.$$

在均方误差意义下, S_n^2 优于 S^2 .

问题是: 是否存在一个 $g(\theta)$ 的估计量 \hat{g} , 使得在均方误差意义下它不劣于其它任意一个估计量?

即, 是否存在: 在均方误差意义下的最优估计? 答案是**否定**的.

事实上, 如果这样的统计量 \hat{g} 存在, 那么对任意给定的 $\theta^* \in \Theta$, $\hat{g}_2 \equiv g(\theta^*)$ 也是一个估计量, 从而

$$\mathbb{E}_{\theta}\{\hat{g} - g(\theta)\}^2 \leq \mathbb{E}_{\theta}\{g(\theta^*) - g(\theta)\}^2, \quad \forall \theta \in \Theta.$$

特别时当 $\theta = \theta^*$ 时有

$$\mathbb{E}_{\theta^*}\{\hat{g} - g(\theta^*)\}^2 = 0.$$

由此得 $\mathbb{P}_{\theta^*}\{\hat{g} = g(\theta^*)\} = 1$. 由 θ^* 的任意性,

$$\mathbb{P}_{\theta}\{\hat{g} = g(\theta)\} = 1, \quad \forall \theta \in \Theta, \quad \text{即 } \hat{g} = g(\theta) \text{ a.s.}$$

最优无偏估计

在均方误差意义下找不到最优估计是因为, 所寻找的范围——所有估计量组成的类——太大.

我们将寻找范围缩小到由无偏估计组成的类:

$$U_g = \{\hat{g} = \hat{g}(\tilde{X}) : \mathbf{E}_\theta \hat{g} = g(\theta), \forall \theta \in \Theta\}.$$

称为 $g(\theta)$ 的**无偏估计类**. U_g 中统计量的均方误差就是它的方差.

U_g 可能是空集. 当它是非空时, 我们称参数 $g(\theta)$ 是**可估参数**.

如: 总体的均值, 若存在, 那它是可估参数.

注意: 不是每个参数都是可估参数的.

Example

设容量为 n 的样本 $\tilde{X} = (X_1, X_2, \dots, X_n)$ 取自 $B(1, p)$, p 为未知参数, $0 < p < 1$. 此时 $g(p) = 1/p$ 就是不可估参数.

事实上, 对任一统计量 $T(\tilde{X})$, 其均值为

$$E_p[T(\tilde{X})] = \sum_{x_i=0,1; i=1,\dots,n} T(\tilde{x}) p^{\sum_i x_i} (1-p)^{n-\sum_i x_i}, \quad \forall p \in (0, 1).$$

上式右端是一个 p 的 n 次多项式, 它必是有界的, 不可能在 $(0, 1)$ 上恒等于无界函数 $1/p$. 所以 $g(p) = 1/p$ 的无偏估计不存在.

对于一个参数 $g(\theta)$, 要找其无偏估计往往也不容易, 通常会从其充分统计量或一些已有的估计量中去挑选或修改. 例如方差的无偏估计 S^2 是从矩法估计 S_n^2 (或写为 $m_{n,2}$)修改得到的.

Example

设 X_1, \dots, X_n 为取自均匀分布 $U(0, \theta)$, $\theta > 0$ 的样本, 问: $1/\theta$ 的无偏估计是否存在? 如存在, 请给出一个; 如不存在, 请说明理由.

解: 考虑基于充分统计量 $X_{(n)} = \max_{1 \leq i \leq n} X_i$ 的估计量 $T(X_{(n)})$, 其均值为

$$E_{\theta}[T(X_{(n)})] = \int_0^{\theta} T(x) \frac{nx^{n-1}}{\theta^n} dx.$$

若 $T(X_{(n)})$ 是 $1/\theta$ 的无偏估计, 则有

$$\frac{1}{\theta} = \int_0^{\theta} T(x) \frac{nx^{n-1}}{\theta^n} dx, \quad \forall \theta > 0.$$

即

$$\theta^{n-1} = \int_0^\theta T(x) n x^{n-1} dx, \quad \forall \theta > 0.$$

再在两端对 θ 求导可解得 $(n-1)\theta^{n-2} = T(\theta)n\theta^{n-1}$, 所以

$$T(\theta) = \frac{n-1}{n\theta}.$$

即此时 $T(x)$ 满足

$$T(x) = \frac{n-1}{nx}.$$

因此当 $n \geq 2$ 时, $T(X_{(n)}) = \frac{n-1}{nX_{(n)}}$ 是 $1/\theta$ 的无偏估计.

而当 $n = 1$ 时, 上述 $T(X_{(n)}) \equiv 0$, 它不满足 $E_\theta[T(X_{(n)})] = 1/\theta$. 可以验证此时 $1/\theta$ 的无偏估计不存在.

Definition

定义 设 $\mathcal{F} = \{p(x; \theta) : \theta \in \Theta\}$ 是一个参数分布族, \tilde{X} 是取自于 $p(x; \theta)$ 的一个样本. 设 $g(\theta)$ 是一个可估参数, U_g 是 $g(\theta)$ 的无偏估计类. 假如 $\hat{g}^* = \hat{g}^*(\tilde{X})$ 是这样一个无偏估计, 对一切 $\hat{g} = \hat{g}(\tilde{X}) \in U_g$, 有

$$\text{Var}_\theta\{\hat{g}^*\} \leq \text{Var}_\theta\{\hat{g}\}, \quad \forall \theta \in \Theta.$$

则称 \hat{g}^* 是 $g(\theta)$ 的**最优无偏估计**, 也称**一致最小方差无偏估计**(uniform minimum variance unbiased estimator), 记为UMVUE.

直接寻找一个UMVUE或证明一个估计量是UMVUE并非易事, 下面的Rao-Blackwell定理给出了一个寻找UMVUE的途径.

Theorem

定理 (Rao-Blackwell) 设 $T = T(\tilde{X})$ 是参数 $\theta \in \Theta$ 的充分统计量, $\varphi(\tilde{X})$ 是参数 $g(\theta)$ 的一个无偏估计. 则

$$\hat{g}(T) = E\{\varphi(\tilde{X})|T\}$$

也是 $g(\theta)$ 的无偏估计, 且

$$\text{Var}_{\theta}\{\hat{g}(T)\} \leq \text{Var}\{\varphi(\tilde{X})\}, \quad \forall \theta \in \Theta.$$

其中等号成立的充分必要条件是

$$P_{\theta}\{\varphi(\tilde{X}) = \hat{g}(T)\} = 1, \quad \forall \theta \in \Theta.$$

定理告诉我们:

- 改善无偏估计方差的方法——现有的无偏估计对充分统计量求条件期望;
- UMVUE一定是充分统计量的函数.

定理的证明: 因为 T 是充分统计量, 在给定 T 的条件下, \tilde{X} 的条件分布与参数 θ 无关, 所以条件期望 $\hat{g}(T) = E\{\varphi(\tilde{X})|T\}$ 与 θ 无关, 从而是统计量. 且

$$E_{\theta}\{\hat{g}(T)\} = E_{\theta}[E\{\varphi(\tilde{X})|T\}] = E_{\theta}\{\varphi(\tilde{X})\} = g(\theta).$$

因此 $\hat{g}(T)$ 是 $g(\theta)$ 的无偏估计量.

下证第二部分结论. 写 $\varphi = \varphi(\tilde{X})$.

$$\begin{aligned}\text{Var}_{\theta}\{\varphi\} &= \text{E}_{\theta}\{\varphi - \text{E}_{\theta}(\varphi)\}^2 \\&= \text{E}_{\theta}\{\varphi - \text{E}_{\theta}(\varphi|T) + \text{E}_{\theta}(\varphi|T) - \text{E}_{\theta}(\varphi)\}^2 \\&= \text{E}_{\theta}\{\varphi - \text{E}_{\theta}(\varphi|T)\}^2 + \text{E}_{\theta}\{\text{E}_{\theta}(\varphi|T) - \text{E}_{\theta}(\varphi)\}^2 \\&\quad + 2\text{E}_{\theta}\{[\varphi - \text{E}_{\theta}(\varphi|T)][\text{E}_{\theta}(\varphi|T) - \text{E}_{\theta}(\varphi)]\} \\&= \text{E}_{\theta}\{\varphi - \hat{g}(T)\}^2 + \text{Var}_{\theta}\{\hat{g}(T)\} \\&\quad + 2\text{E}_{\theta}\{[\varphi - \text{E}_{\theta}(\varphi|T)][\text{E}_{\theta}(\varphi|T) - \text{E}_{\theta}(\varphi)]\}.\end{aligned}$$

由于

$$\begin{aligned}& \mathbf{E}_{\theta} \left\{ [\varphi - \mathbf{E}_{\theta}(\varphi|T)] [\mathbf{E}_{\theta}(\varphi|T) - \mathbf{E}_{\theta}(\varphi)] \right\} \\&= \mathbf{E}_{\theta} \left(\mathbf{E}_{\theta} \left\{ [\varphi - \mathbf{E}_{\theta}(\varphi|T)] [\mathbf{E}_{\theta}(\varphi|T) - \mathbf{E}_{\theta}(\varphi)] \middle| T \right\} \right) \\&= \mathbf{E}_{\theta} \left(\mathbf{E}_{\theta} \left\{ [\varphi - \mathbf{E}_{\theta}(\varphi|T)] \middle| T \right\} \cdot [\mathbf{E}_{\theta}(\varphi|T) - \mathbf{E}_{\theta}(\varphi)] \right) \\&= \mathbf{E}_{\theta} \left([\mathbf{E}_{\theta}(\varphi|T) - \mathbf{E}_{\theta}(\varphi|T)] \cdot [\mathbf{E}_{\theta}(\varphi|T) - \mathbf{E}_{\theta}(\varphi)] \right) = 0.\end{aligned}$$

故得

$$\begin{aligned}\mathbf{Var}_{\theta}\{\varphi\} &= \mathbf{E}_{\theta}\{\varphi - \hat{g}(T)\}^2 + \mathbf{Var}_{\theta}\{\hat{g}(T)\} \\&\geq \mathbf{Var}_{\theta}\{\hat{g}(T)\}, \quad \forall \theta \in \Theta.\end{aligned}$$

等号成立当且仅当 $\mathbf{E}_{\theta}\{\varphi - \hat{g}(T)\}^2 = 0$, 即 $\mathbf{P}_{\theta}\{\varphi = \hat{g}(T)\} = 1$.

Theorem

设 $T = T(\tilde{X})$ 是参数 $\theta \in \Theta$ 的充分统计量, $\varphi(\tilde{X}) = (\varphi_1(\tilde{X}), \dots, \varphi_k(\tilde{X}))$ 是取值在 \mathbf{R}^k 上的参数 $\mathbf{g}(\theta)$ 的一个无偏估计. 则

- ① $\hat{\mathbf{g}}(T) = E\{\varphi(\tilde{X})|T\}$ 也是 $\mathbf{g}(\theta)$ 的无偏估计,
- ② 若记 $\hat{\mathbf{g}}(T)$ 和 $\varphi(\tilde{X})$ 的协方差矩阵分别为

$$\mathbf{V}(\theta) = \{ \text{Cov}_{\theta}[\hat{g}_i(T), \hat{g}_j(T)] \}_{1 \leq i, j \leq k},$$

$$\mathbf{U}(\theta) = \left\{ \text{Cov}_{\theta}[\varphi_i(\tilde{X}), \varphi_j(\tilde{X})] \right\}_{1 \leq i, j \leq k},$$

则

$$\mathbf{U}(\theta) - \mathbf{V}(\theta) \text{ 非负定, } \forall \theta \in \Theta,$$

且 $\mathbf{U}(\theta) - \mathbf{V}(\theta)$ 为零矩阵的充分必要条件是

$$P_{\theta}\{\varphi(\tilde{X}) = \hat{\mathbf{g}}(T)\} = 1, \quad \forall \theta \in \Theta.$$

Example

设 X_1, X_2, \dots, X_n 是来自二点分布 $B(1, p)$ 的一个样本, 讨论 p 的无偏估计.

X_1 是 p 的无偏估计($\because EX_1 = p$), 而 $T = X_1 + \dots + X_n$ 是参数 p 的充分统计量. 我们用求条件期望的方法改进无偏估计.

$$E(X_1|T) = E(X_2|T) = \dots = E(X_n|T).$$

所以

$$\begin{aligned} E(X_1|T) &= \frac{E(X_1|T) + E(X_2|T) \cdots + E(X_n|T)}{n} \\ &= \frac{E(X_1 + X_2 \cdots + X_n|T)}{n} \\ &= \frac{E(T|T)}{n} = \frac{T}{n} = \bar{X}. \end{aligned}$$

零无偏估计法

Theorem

定理3.4.1 设 $\hat{g} = \hat{g}(\tilde{X})$ 是 $g(\theta)$ 的一个无偏估计. $\text{Var}_\theta(\hat{g}) < \infty$ (对 $\forall \theta \in \Theta$). 记零无偏估计集

$$\mathcal{L} = \{l = l(\tilde{X}) : E_\theta(l(\tilde{X})) = 0, \forall \theta \in \Theta\}.$$

若对 $\forall l \in \mathcal{L}$, 有

$$\text{Cov}_\theta(\hat{g}, l) = E_\theta(\hat{g} \cdot l) = 0, \quad \forall \theta \in \Theta, \quad (3.4.2)$$

则 \hat{g} 必为 $g(\theta)$ 的 *UMVUE*.

证明: 设 $\hat{g}_1 = \hat{g}_1(\tilde{X})$ 是 $g(\theta)$ 的任一无偏估计. 记 $l = l(\tilde{X}) = \hat{g}_1 - \hat{g}$, 则 $E(l(\tilde{X})) = 0$, 故 $l \in \mathcal{L}$. 利用(3.4.2), 可得

$$\begin{aligned}\text{Var}_\theta(\hat{g}_1) &= \text{Var}_\theta(\hat{g} + l) = \text{Var}_\theta(\hat{g}) + \text{Var}(l) + 2\text{Cov}_\theta(\hat{g}, l) \\ &= \text{Var}_\theta(\hat{g}) + \text{Var}(l) \geq \text{Var}_\theta(\hat{g}), \quad \forall \theta \in \Theta.\end{aligned}$$

这就意味着 \hat{g} 为 $g(\theta)$ 的UMVUE.

Example

设 X_1, X_2, \dots, X_n 是来自二点分布 $B(1, p)$ 的一个样本, $0 < p < 1$, 证明 \bar{X} 为 p 的 UMVUE.

证明: 由于 $E_p(\bar{X}) = p$ 且 $\text{Var}_p(\bar{X}) = p(1-p)/n < \infty$. 故由定理3.4.1知, 要证 \bar{X} 为 p 的 UMVUE, 只需证明 \bar{X} 满足(3.4.2)即可. 现设 $l = l(\tilde{X})$ 为零无偏估计, 则

$$0 = E_p(l) = \sum_{x_i=0,1; i=1,\dots,n} l(\tilde{x}) p^{\sum_{i=1}^n x_i} (1-p)^{n-\sum_{i=1}^n x_i}, \quad \forall p \in (0, 1).$$

令 $\theta = \frac{p}{1-p}$, 则有

$$0 = \sum_{x_i=0,1; i=1,\dots,n} l(\tilde{x}) \theta^{\sum_{i=1}^n x_i}, \quad \forall \theta > 0 \quad (\clubsuit 1).$$

对(✂1)式的两边关于 θ 求导,得

$$0 = \sum_{x_i=0,1;i=1,\dots,n} \left(\sum_{i=1}^n x_i \right) \cdot l(\tilde{x}) \theta^{\sum_{i=1}^n x_i - 1}, \quad \forall \theta > 0,$$

故

$$0 = \sum_{x_i=0,1;i=1,\dots,n} \left(\sum_{i=1}^n x_i \right) \cdot l(\tilde{x}) \theta^{\sum_{i=1}^n x_i}, \quad \forall \theta > 0,$$

从而 $\text{Cov}_p(\bar{X}, l(\tilde{X})) = \mathbb{E}_p(\bar{X} \cdot l(\tilde{X})) = 0$, 即(3.4.2)成立. 所以 \bar{X} 为 p 的UMVUE.

Corollary

推论3.4.1 设 $T = T(\tilde{X})$ 为 θ 的充分统计量, $h(T)$ 是 $g(\theta)$ 的一个无偏估计量, 且 $\text{Var}_\theta(h(T)) < \infty$ (对 $\forall \theta \in \Theta$). 记

$$\mathcal{L}_T = \{\delta = \delta(T) : E_\theta(\delta(T)) = 0, \forall \theta \in \Theta\}.$$

若对 $\forall \delta \in \mathcal{L}_T$, 有

$$\text{Cov}_\theta(h(T), \delta(T)) = E_\theta(h(T) \cdot \delta(T)) = 0, \quad \forall \theta \in \Theta, \quad (3.4.3)$$

则 $h(T)$ 必为 $g(\theta)$ 的UMVUE.

Example

设 X_1, X_2, \dots, X_n 是来自二点分布 $B(1, p)$ 的一个样本, 证明 \bar{X} 为 p 的UMVUE.

证明: 已知 $T = \sum_{i=1}^n X_i$ 为 p 的充分统计量, 并且 $\bar{X} = T/n$, $E_p(\bar{X}) = p$, $\text{Var}_p(\bar{X}) = p(1-p)/n < \infty$. 由推论3.4.1知, 要证 \bar{X} 为 p 的UMVUE, 只需证明 \bar{X} 满足(3.4.3)即可. 现设 $\delta(T) \in \mathcal{L}_T$, 即 $E_p(\delta(T)) = 0$. 注意到 $T \sim B(n, p)$, 则

$$0 = E_p(\delta(T)) = \sum_{k=0}^n \delta(k) \binom{n}{k} p^k (1-p)^{n-k}, \quad \forall p \in (0, 1).$$

令 $\theta = \frac{p}{1-p}$, 并约去非零项, 则有

$$0 = \sum_{k=0}^n \delta(k) \binom{n}{k} \theta^k, \quad \forall \theta > 0 \quad (\text{✖2}).$$

对(✂2)式的两边关于 θ 求导,得

$$0 = \sum_{k=0}^n k \cdot \delta(k) \binom{n}{k} \theta^{k-1}, \quad \forall \theta > 0,$$

故

$$0 = \sum_{k=0}^n k \cdot \delta(k) \binom{n}{k} \theta^k, \quad \forall \theta > 0,$$

从而 $\text{Cov}_p(\bar{X}, \delta(T)) = \mathbb{E}_p(\bar{X} \cdot \delta(T)) = \frac{1}{n} \mathbb{E}_p(T \cdot \delta(T)) = 0$, 即(3.4.3)成立. 据推论3.4.1, 可知 \bar{X} 为 p 的UMVUE.

思考:

由前面的讨论中, 我们得知:

设 $h(T)$ 是 $g(\theta)$ 的一个无偏估计, 其中 T 为 θ 的充分统计量. 如果 $h(T)$ 与任意一个 T 的函数类中的零无偏估计的乘积的期望为0(此时称两个随机变量正交), 那么可以推出 $h(T)$ 是 $g(\theta)$ 的UMVUE.

显然零属于 T 的函数类, 也是一个零无偏估计, 而且零与任何随机变量正交.

如果 T 的函数类中的“零无偏估计只有零”, 那么这个无偏估计 $h(T)$ 一定与之正交, 那么它也就是 $g(\theta)$ 的UMVUE.

什么叫 T 的函数类中的“零无偏估计只有零”

$$E_{\theta}\varphi(T) = 0, \quad \forall \theta \in \Theta$$

$$\Downarrow$$

$$P_{\theta}\{\varphi(T) = 0\} = 1, \quad \forall \theta \in \Theta.$$

完备性(或称完全性)

Definition

定义 设 X 的分布所在的分布族为 $\mathcal{F} = \{p(x; \theta) : \theta \in \Theta\}$. 假如对任一个实函数 $\varphi(x)$, 由

$$E_{\theta}\varphi(X) = 0, \quad \forall \theta \in \Theta$$

可推出

$$P_{\theta}\{\varphi(X) = 0\} = 1, \quad \forall \theta \in \Theta.$$

则称此分布族 \mathcal{F} 是完备的(或称为完全的).

Example

例 二项分布族 $\{B(n, p) : 0 < p < 1\}$ 是完备的.

证: 假如 $\varphi(x)$ 满足

$$E_p \varphi(X) = \sum_{x=0}^n \varphi(x) \binom{n}{x} p^x (1-p)^{n-x} = 0, \quad \forall p \in (0, 1).$$

令 $\theta = p/(1-p)$, 则上式可改写为

$$\sum_{x=0}^n \binom{n}{x} \varphi(x) \theta^x = 0, \quad \forall \theta > 0.$$

上式为 θ 的多项式, 而 $\binom{n}{x} \varphi(x)$ 是多项式的系数, 所以 $\varphi(x) = 0$

$(x = 0, 1, \dots, n)$. 又 $P_p(X = 0, 1, \dots, n) = 1, \forall p \in (0, 1)$,

故 $P_p\{\varphi(X) = 0\} = 1, \forall p \in (0, 1)$. 所以二项分布族是完备的.

Example

正态分布族 $\{N(0, \sigma^2) : \sigma > 0\}$ 是不完备的.

$$\varphi(x) = x.$$

Example

Gamma分布族 $\{\Gamma(\alpha, \lambda) : \lambda > 0\}$ 是完备的(其中 $\alpha > 0$ 已知).

证明: 设实函数 $\varphi(t)$ 满足 $E_{\lambda}\varphi(\Gamma) = 0$, 其中 $\Gamma \sim \Gamma(\alpha, \lambda)$, 即

$$\int_0^{\infty} \varphi(t) t^{\alpha-1} e^{-\lambda t} dt = 0, \quad \forall \lambda > 0.$$

上式左边是 $\varphi(t)t^{\alpha-1}$ 的Laplace变换, 由Laplace变换的唯一性知:

$$\varphi(t)t^{\alpha-1} = 0 \quad a.e., \quad \forall t > 0, \quad \text{故} \quad \varphi(t) = 0 \quad a.e. \quad \forall t > 0.$$

注意到 $P_{\lambda}(\Gamma > 0) = 1, \forall \lambda > 0$, 所以

$$P_{\lambda}\{\varphi(\Gamma) = 0\} = 1, \quad \forall \lambda > 0.$$

Example

正态分布族 $\{N(\mu, \sigma^2) : -\infty < \mu < \infty\}$ 是完备的, 其中 σ 已知.

证明: 设实函数 $\varphi(x)$ 满足 $E_{\mu}\varphi(X) = 0$, 其中 $X \sim N(\mu, \sigma^2)$, 即

$$\int_{-\infty}^{\infty} \varphi(x) \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx = 0 \quad \forall \mu \in \mathbb{R},$$

$$\frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{\mu^2}{2\sigma^2}} \int_{-\infty}^{\infty} \varphi(x) e^{-\frac{x^2}{2\sigma^2}} e^{\frac{\mu}{\sigma^2}x} dx = 0 \quad \forall \mu \in \mathbb{R}.$$

也即

$$\int_{-\infty}^{\infty} \left[\varphi(x) e^{-\frac{x^2}{2\sigma^2}} \right] e^{-\lambda x} dx = 0 \quad \forall \lambda \in \mathbb{R}.$$

上式左边是 $\varphi(x) e^{-\frac{x^2}{2\sigma^2}}$ 的Laplace变换, 从而

$$\varphi(x) e^{-\frac{x^2}{2\sigma^2}} = 0, \quad a.e.$$

即 $\varphi(x) = 0$ a.e. 所以

$$P_{\mu}\{\varphi(X) = 0\} = 1.$$

Definition

定义 设有参数分布族 $\mathcal{F} = \{p(x; \theta) : \theta \in \Theta\}$. T 是一个统计量. 假如对任一实函数 $\varphi(t)$, 由

$$E_{\theta} \varphi(T) = 0, \quad \forall \theta \in \Theta$$

可推出

$$P_{\theta}\{\varphi(T) = 0\} = 1, \forall \theta \in \Theta,$$

也就是说, 由 T 诱导出的分布族 $\mathcal{F}^T = \{p_T(t; \theta) : \theta \in \Theta\}$ 是完备的, 则称 T 是完备统计量.

$\{N(0, \sigma^2) : \sigma > 0\}$ 不完备, 但统计量 $T = X_1^2 + \cdots + X_n^2 \sim \Gamma(\frac{n}{2}, \frac{1}{2\sigma^2})$ 是完备统计量.

Example

设 X_1, X_2, \dots, X_n 是来自正态总体 $N(\mu, \sigma^2)$ 的样本. 证明 (\bar{X}, S^2) 是完备统计量.

证明: 设有 $\varphi(x, t)$ 使得 $E_{\mu, \sigma^2} \varphi(\bar{X}, S^2) = 0$. 由于 $\bar{X} \sim N(\mu, \sigma^2/n)$, $(n-1)S^2/\sigma^2 \sim \chi^2(n-1) = \Gamma(\frac{n-1}{2}, \frac{1}{2})$, 所以 $S^2 \sim \Gamma(\frac{n-1}{2}, \frac{n-1}{2\sigma^2})$. 且 \bar{X} 和 S^2 相互独立, 从而

$$\int_{-\infty}^{\infty} \left[\int_0^{\infty} \varphi(x, t) f_{\sigma^2}(t) dt \right] \frac{1}{\sqrt{2\pi\sigma^2/n}} e^{-\frac{(x-\mu)^2}{2\sigma^2/n}} dx = 0, \quad \forall \sigma > 0, \mu \in \mathbb{R},$$

其中 $f_{\sigma^2}(t)$ 为 $\Gamma(\frac{n-1}{2}, \frac{n-1}{2\sigma^2})$ 的密度函数. 先固定 σ^2 , 上式对 $\forall \mu \in \mathbb{R}$ 成立, 由正态分布族 $\{N(\mu, \sigma^2/n), -\infty < \mu < \infty\}$ 的完备性知

$$\int_0^{\infty} \varphi(x, t) f_{\sigma^2}(t) dt = 0, a.e., \quad \forall \sigma > 0.$$

再由gamma分布族的完备性知道

$$\varphi(x, t) = 0, a.e..$$

所以 (\bar{X}, S^2) 是完备统计量.

Example

设 X_1, X_2, \dots, X_n 是来自均匀分布总体 $U(\theta - 1/2, \theta + 1/2)$ 的简单随机样本, $n \geq 1$, 其中 $\theta \in \mathbb{R}$. 记 $T = (X_{(1)}, X_{(n)})$, 证明 T 是 θ 的充分统计量, 但不是完备统计量.

证明: 由于 (X_1, X_2, \dots, X_n) 的联合概率密度函数为

$$\begin{aligned} p(\tilde{x}; \theta) &= \prod_{i=1}^n 1 \cdot I_{\{\theta - 1/2 < x_i < \theta + 1/2, i=1, 2, \dots, n\}} \\ &= I_{\{\theta - 1/2 < x_{(1)} \leq x_{(n)} < \theta + 1/2\}}, \end{aligned}$$

其中 $x_{(1)} = \min\{x_i, i = 1, \dots, n\}$, $x_{(n)} = \max\{x_i, i = 1, \dots, n\}$. 令 $h(\tilde{x}) = 1$, 根据因子分解定理, 可知 $T = (X_{(1)}, X_{(n)})$ 是 θ 的充分统计量.

为证 T 是不完备的, 只需找到一个在概率意义下非0的 $\varphi(T) = \varphi(X_{(1)}, X_{(n)})$, 且满足 $E_{\theta}(\varphi(T)) = E_{\theta}(\varphi(X_{(1)}, X_{(n)})) = 0$. 令 $Y_i = \frac{X_i - (\theta - 1/2)}{1}$, 则 Y_1, Y_2, \dots, Y_n 相互独立, 且均服从 $U(0, 1)$, 并记 $Y_{(1)} = \min\{Y_i, i = 1, \dots, n\}$, $Y_{(n)} = \max\{Y_i, i = 1, \dots, n\}$, 则

$$X_{(n)} - X_{(1)} = Y_{(n)} - Y_{(1)},$$

其分布与参数 θ 无关. 又注意到

$$E_{\theta}(X_{(n)} - X_{(1)}) = E(Y_{(n)} - Y_{(1)}) = c_n = \frac{n-1}{n+1}.$$

故可取 $\varphi(T) = X_{(n)} - X_{(1)} - c_n$, 此时有

$$E_{\theta}(\varphi(T)) = 0, \quad \forall \theta \in \mathbb{R}.$$

但 $P_{\theta}(X_{(n)} - X_{(1)} - c_n = 0) = 0 \neq 1, \quad \forall \theta \in \mathbb{R}.$

Theorem

定理2.8.2 (Basu定理) 设总体 X 的分布所在的分布族

为 $\mathcal{F} = \{p(x; \theta) : \theta \in \Theta\}$, $\tilde{X} = (X_1, X_2, \dots, X_n)$ 是从该总体中抽取的简单随机样本. 设 $T = T(\tilde{X})$ 是一完备统计量, 且为参数 θ 的充分统计量. 若随机变量 $V = V(\tilde{X})$ 的分布与参数 θ 无关, 则对于任何 $\theta \in \Theta$, T 与 V 独立.

证明: 要证明 T 与 V 独立, 只需证: 对于任意的Borel集 A, B , 有

$$P_{\theta}(T \in A, V \in B) = P_{\theta}(T \in A) \cdot P_{\theta}(V \in B), \quad \forall \theta \in \Theta.$$

由于 V 的分布与参数 θ 无关, 则可令

$$b = P_{\theta}(V \in B),$$

b 为与参数 θ 无关的常数. 并记

$$\psi(T) = E(I_{\{V \in B\}}|T).$$

注意到 T 为参数 θ 的充分统计量, 因此 $\psi(T)$ 与参数 θ 无关, 仅为 T 的函数. 又

$$E_{\theta}(\psi(T) - b) = E_{\theta}(E(I_{\{V \in B\}}|T)) - b = P(V \in B) - P(V \in B) = 0, \quad \forall \theta \in \Theta.$$

由于 T 的完备性, 可知

$$\psi(T) - b = 0, \quad a.s. \quad P_{\theta}, \quad \forall \theta \in \Theta,$$

即

$$\psi(T) = b, \quad a.s. \quad P_{\theta}, \quad \forall \theta \in \Theta.$$

因此

$$\begin{aligned} P_{\theta}(T \in A, V \in B) &= E_{\theta}(I_{\{T \in A, V \in B\}}) \\ &= E_{\theta}(I_{\{T \in A\}} \cdot I_{\{V \in B\}}) = E_{\theta}(E_{\theta}(I_{\{T \in A\}} \cdot I_{\{V \in B\}} | T)) \\ &= E_{\theta}(I_{\{T \in A\}} \cdot E_{\theta}(I_{\{V \in B\}} | T)) = E_{\theta}(I_{\{T \in A\}} \cdot \psi(T)) \\ &= E_{\theta}(I_{\{T \in A\}} \cdot b) = E_{\theta}(I_{\{T \in A\}}) \cdot b \\ &= P_{\theta}(T \in A) \cdot b = P_{\theta}(T \in A) \cdot P_{\theta}(V \in B). \end{aligned}$$

Example

设 X_1, X_2, \dots, X_n 是来自正态总体 $N(\mu, \sigma^2)$ 的样本, 利用Busa定理, 可得对于任意的参数 $\mu \in \mathbb{R}, \sigma > 0$, 样本偏度

$$\frac{\sqrt{n} \sum_{i=1}^n (X_i - \bar{X})^3}{(\sum_{i=1}^n (X_i - \bar{X})^2)^{3/2}} = \frac{m_{n,3}}{m_{n,2}^{2/3}}$$

与 (\bar{X}, S^2) 独立.

因为

$$\frac{m_{n,3}}{m_{n,2}^{2/3}} = \frac{\sqrt{n} \sum_{i=1}^n (Y_i - \bar{Y})^3}{(\sum_{i=1}^n (Y_i - \bar{Y})^2)^{3/2}},$$

其中 $Y_i = \frac{X_i - \mu}{\sigma}$, i.i.d., 服从标准正态, 即样本偏度的分布与参数 μ, σ 无关. 根据Basu定理, 可知对于任意的参数 $\mu \in \mathbb{R}, \sigma > 0$, $\frac{m_{n,3}}{m_{n,2}^{2/3}}$ 与参数 (μ, σ) 的充分统计量 (\bar{X}, S^2) 独立.

Rao-Blackwell定理说明, 如果 T 是 θ 的充分统计量, 则可估参数 $g(\theta)$ 的UMVUE可以在 T 的函数类中寻找.

由零无偏估计法(推论)可知, 可估参数 $g(\theta)$ 一个无偏估计 $h(T)$, 其中 T 为 θ 的充分统计量, 如果满足 $h(T)$ 与任意一个 T 的函数类中的零无偏估计的乘积的期望为0(此时称两个随机变量正交), 那么可以推出 $h(T)$ 是 $g(\theta)$ 的UMVUE.

而完备性告诉我们, 如果 T 是完备统计量, 则在 T 的函数类中, 只有零是零的无偏估计, 即对于任何满足 $E_{\theta}l(T) = 0, \quad \forall \theta \in \Theta$ 的 $l(T)$ 必有 $P(l(T) = 0) = 1$.

从而, 如果 T 既是充分的又是完备的, 那么只要 $\varphi(\tilde{X})$ 是 $g(\theta)$ 的无偏估计, 那么 $E[\varphi(\tilde{X})|T]$ 就是 $g(\theta)$ 的UMVUE.

充分完备统计量法

Theorem

定理3.4.2 (*Lehmann – Scheffè*, 简称**LS定理**) 设 $S = S(\tilde{X})$ 是参数 θ 的充分完备统计量(*complete sufficient statistic*), 则可估参数 $g(\theta)$ 的UMVUE存在且唯一.

若 $\varphi(\tilde{X})$ 是 $g(\theta)$ 的一个无偏估计, 那么 $g(\theta)$ 唯一的UMVUE就是

$$E[\varphi(\tilde{X})|S].$$

上面的定理给出了我们找UMVUE的方法:

1. 先找一个充分完备统计量 S , 再找一个可估参数的无偏估计 φ , 计算条件期望 $E[\varphi|S]$ 就得UMVUE.
2. 先找一个充分完备统计量 S , 再找一个 S 的函数 $h(S)$ 使得它是可估参数的无偏估计, $h(S)$ 即为所求的UMVUE.

Example

设总体 X 来自两点分布族 $\{B(1, p); 0 < p < 1\}$. $\tilde{X} = (X_1, X_2, \dots, X_n)$ 为从中抽取的简单随机样本. 我们已证 $T = \sum_{i=1}^n X_i$ 是参数 p 的充分完备统计量. 下求 p 的UMVUE.

由无偏估计 X_1 算得 $E[X_1|T] = T/n = \bar{X}$, \bar{X} 就是 p 的UMVUE.

Example

下求 p^2 的UMVUE.

因为

$$\mathbb{E}T^2 = \sum_{i=1}^n \mathbb{E}X_i^2 + \sum_{i \neq j} \mathbb{E}X_i \mathbb{E}X_j = \mathbb{E}T + n(n-1)p^2.$$

所以

$$p^2 = \frac{\mathbb{E}(T^2 - T)}{n(n-1)} = \mathbb{E} \left(\frac{T^2 - T}{n(n-1)} \right).$$

故

$$\frac{T^2 - T}{n(n-1)} = \frac{1}{n-1} (n\bar{X}^2 - \bar{X})$$

就是 p^2 的UMVUE.

LS定理的证明:

存在性: 设 $\varphi = \varphi(\tilde{X})$ 是可估参数 $g(\theta)$ 的一个无偏估计. 记

$$\hat{g} = \hat{g}(\tilde{X}) = E[\varphi|S].$$

由定理(Rao-Blackwell), 知 \hat{g} 也是 $g(\theta)$ 的无偏估计. 下面我们证明上述 \hat{g} 就是 $g(\theta)$ 的UMVUE. 设 $\hat{f} = f(\tilde{X})$ 是 $g(\theta)$ 的其它的任意一个无偏估计. 由Rao-Blackwell定理, $E[\hat{f}|S]$ 也是 $g(\theta)$ 的无偏估计. 且

$$\text{Var}_{\theta}\{E[\hat{f}|S]\} \leq \text{Var}_{\theta}\{\hat{f}\}.$$

由于 \hat{g} 和 $E[\hat{f}|S]$ 都是 $g(\theta)$ 的无偏估计, 即, $E_{\theta}\{\hat{g} - E[\hat{f}|S]\} = 0, \forall \theta$. 且 \hat{g} 和 $E[\hat{f}|S]$ 都是 S 的函数, 故由 S 的完备性, 可知 $P_{\theta}\{\hat{g} = E[\hat{f}|S]\} = 1$. 从而

$$\text{Var}_{\theta}\{\hat{g}\} = \text{Var}_{\theta}\{E[\hat{f}|S]\} \leq \text{Var}_{\theta}\{\hat{f}\}.$$

所以 \hat{g} 是 $g(\theta)$ 的UMVUE.

唯一性: 设 $W = W(\tilde{X})$ 和 $Y = Y(\tilde{X})$ 都是 $g(\theta)$ 的UMVUE. 则由定义必有

$$E_{\theta}W = E_{\theta}Y = g(\theta), \quad \text{Var}_{\theta}\{W\} = \text{Var}_{\theta}\{Y\} \quad \forall \theta.$$

注意到

$$\begin{aligned} E_{\theta}\{W - Y\}^2 &= \text{Var}_{\theta}\{W - Y\} \\ &= \text{Var}_{\theta}\{W\} + \text{Var}_{\theta}\{Y\} - 2\text{Cov}_{\theta}\{W, Y\} \\ &= 2\text{Var}_{\theta}\{W\} - 2\text{Cov}_{\theta}\{W, Y\}. \end{aligned}$$

如果能够证明

$$\text{Cov}_\theta\{W, Y\} = \text{Var}_\theta\{W\} = \text{Var}_\theta\{Y\}.$$

那么就有 $E_\theta\{W - Y\}^2 = 0$. 因而得证:

$$P_\theta\{W = Y\} = 1, \quad \forall \theta.$$

为证 $\text{Cov}_\theta\{W, Y\} = \text{Var}_\theta\{W\}$, 记 $Z = (W + Y)/2$, 那么 Z 也是 $g(\theta)$ 的无偏估计. 由于 W 是 UMVUE, 从而

$$\begin{aligned}\text{Var}_\theta\{W\} &\leq \text{Var}_\theta\{Z\} \\&= \frac{1}{4}\text{Var}_\theta\{W\} + \frac{1}{4}\text{Var}_\theta\{Y\} + \frac{1}{2}\text{Cov}_\theta\{W, Y\} \\&\leq \frac{1}{4}\text{Var}_\theta\{W\} + \frac{1}{4}\text{Var}_\theta\{Y\} + \frac{1}{2}(\text{Var}_\theta\{W\})^{1/2} \cdot (\text{Var}_\theta\{Y\})^{1/2} \\&\quad (\text{Cauchy-Schwarz不等式}) \\&= \text{Var}_\theta\{W\}.\end{aligned}$$

所以

$$\text{Cov}_\theta\{W, Y\} = \text{Var}_\theta\{W\} = \text{Var}_\theta\{Y\}.$$

Example

设 X_1, X_2, \dots, X_n 是来自参数为 λ 的Poisson总体的一个样本, $\lambda > 0$ 未知. 求:

- (1) 参数 λ 的UMVUE;
- (2) 概率

$$P_{\lambda}(k) = \frac{\lambda^k}{k!} e^{-\lambda}$$

的UMVUE($k = 0, 1, \dots$).

解: 先求 λ 的充分完备统计量.

注意到, X_1, X_2, \dots, X_n 的联合分布列为

$$\begin{aligned} & P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n) \\ &= e^{-\lambda n} \lambda^{x_1+x_2+\dots+x_n} \frac{1}{x_1!x_2!\dots x_n!} \cdot I\{x_i = 0, 1, \dots; i = 1, 2, \dots, n\}. \end{aligned}$$

取 $g(T(\tilde{x}); \lambda) = e^{-\lambda n} \lambda^{x_1+x_2+\dots+x_n}$,

$h(\tilde{x}) = \frac{1}{x_1!x_2!\dots x_n!} \cdot I\{x_i = 0, 1, \dots; i = 1, 2, \dots, n\}$, 那么由因子分解定理知,

$T_n = \sum_{i=1}^n X_i$ 是充分统计量.

下证明它是完备统计量. 由于 $T_n \sim P(n\lambda)$, 如果

$$E_{\lambda}f(T_n) = e^{-n\lambda} \sum_{t=0}^{+\infty} f(t) \frac{(n\lambda)^t}{t!} = 0, \quad \forall \lambda > 0,$$

令 $\delta = n\lambda$, 去掉非零项, 即

$$\sum_{t=0}^{+\infty} f(t) \frac{\delta^t}{t!} = 0, \quad \forall \delta > 0$$

成立, 那么对 $t = 0, 1, 2, \dots$, 必有 δ^t 的系数都为零, 即

$$f(t) \frac{1}{t!} = 0, \quad t = 0, 1, 2, \dots,$$

所以 $f(t) = 0, t = 0, 1, 2, \dots$. 又 $P_{\lambda}(T_n = 0, 1, 2, \dots) = 1$, 从而 $P_{\lambda}\{f(T_n) = 0\} = 1$, 故 T_n 是完备的.

(1) 由于统计量 $\bar{X} = \frac{T_n}{n}$ 为 T_n 的函数, 而且 $E\bar{X} = EX = \lambda$, 即 \bar{X} 是 λ 的无偏估计, 据LS定理可知 \bar{X} 是 λ 的UMVUE.

(2) 统计量

$$\varphi_k(\tilde{X}) = \begin{cases} 1, & X_1 = k, \\ 0, & X_1 \neq k \end{cases}$$

是 $P_\lambda(k)$ 的无偏估计. 那么对于 $t \geq k$, k, t 均为非负整数, 有

$$\begin{aligned} E_\lambda[\varphi_k(\tilde{X})|T_n = t] &= 1 \cdot P(\varphi_k(\tilde{X}) = 1|T_n = t) = P(X_1 = k|T_n = t) \\ &= \frac{P(X_1 = k, T_n = t)}{P(T_n = t)} = \frac{P(X_1 = k)P(X_2 + \cdots + X_n = t - k)}{P(T_n = t)} \\ &= \frac{\frac{\lambda^k}{k!} e^{-\lambda} \cdot \frac{[(n-1)\lambda]^{t-k}}{(t-k)!} e^{-(n-1)\lambda}}{\frac{(n\lambda)^t}{t!} e^{-n\lambda}} = \binom{t}{k} \left(\frac{1}{n}\right)^k \left(1 - \frac{1}{n}\right)^{t-k}. \end{aligned}$$

故 $P_\lambda(k)$ 的UMVUE为

$$\widehat{P_\lambda(k)} = \binom{T_n}{k} \left(\frac{1}{n}\right)^k \left(1 - \frac{1}{n}\right)^{T_n-k} I\{T_n \geq k\}.$$

特别地

$$\widehat{P_\lambda(0)} = \widehat{e^{-\lambda}} = \left(1 - \frac{1}{n}\right)^{T_n}.$$

Example

例 设 X_1, X_2, \dots, X_n 是取自均匀分布 $U(0, \theta)$ 的一个样本, $\theta > 0$ 未知, $n \geq 2$. 求参数 θ 的UMVUE. 并比较它与矩法估计的有效性.

解: 先找一个充分完备统计量. 已证明 $T = X_{(n)}$ 是充分统计量. 下证它的完备性. $X_{(n)}$ 的密度函数为

$$p(t; \theta) = \frac{n}{\theta^n} t^{n-1}, \quad 0 < t < \theta.$$

如果

$$E_{\theta}\varphi(X_{(n)}) = \int_0^{\theta} \varphi(t) \frac{n}{\theta^n} t^{n-1} dt = 0, \quad \forall \theta > 0,$$

即

$$\int_0^{\theta} \varphi(t) t^{n-1} dt = 0, \quad \forall \theta > 0.$$

对 θ 求导数得

$$\varphi(\theta)\theta^{n-1} = 0, \quad \forall \theta > 0.$$

故

$$\varphi(t) = 0, \quad \forall t > 0.$$

注意到 $P(X_{(n)} > 0) \geq P(0 < X_{(n)} < \theta) = 1$, 故 $P(\varphi(X_{(n)}) = 0) = 1$, 即 $X_{(n)}$ 的完备性得证.

由于

$$\mathbb{E}X_{(n)} = \int_0^\theta t \cdot \frac{n}{\theta^n} t^{n-1} dt = \frac{n}{n+1} \theta.$$

所以 $\hat{\theta} = (1 + \frac{1}{n})X_{(n)}$ 是 θ 的无偏估计. 因为它是充分完备统计量的函数. 所以它是 θ 的UMVUE.

下面求 $\hat{\theta}$ 的方差.

$$\mathbb{E}X_{(n)}^2 = \int_0^\theta t^2 \cdot \frac{n}{\theta^n} t^{n-1} dt = \frac{n}{n+2} \theta^2.$$

所以

$$\text{Var}(\hat{\theta}) = \mathbb{E}\hat{\theta}^2 - \theta^2 = (1 + \frac{1}{n})^2 \frac{n}{n+2} \theta^2 - \theta^2 = \frac{\theta^2}{n(n+2)}.$$

由于 $EX = \frac{\theta}{2}$, $\theta = 2EX$. 所以 θ 的矩法估计为

$$\hat{\theta}_1 = 2\bar{X}.$$

$$\text{Var}(\hat{\theta}_1) = 4\text{Var}(\bar{X}) = 4\frac{\theta^2}{12n} = \frac{\theta^2}{3n}.$$

这里, 当 $n \geq 2$ 时, UMVUE 比矩法估计有效.

Theorem

设总体来自指数型分布族, 从总体中抽取的样本的联合 *pdf* 或 *pmf* 为

$$p(\tilde{x}; \theta) = c^*(\theta) \exp \left\{ \sum_{j=1}^k Q_j(\theta) T_j^*(\tilde{x}) \right\} h^*(\tilde{x}),$$

若 $\mathbf{Q} = (Q_1(\theta), \dots, Q_k(\theta))$ 的值域有非空的内部, 则 $T = (T_1^*, \dots, T_k^*)$ 为充分完备统计量.

Example

设 X_1, X_2, \dots, X_n 是来自正态总体 $N(\mu, \sigma^2)$ 的样本, $-\infty < \mu < \infty, \sigma > 0$ 未知. 求 μ 和 σ^2 的UMVUE.

解: 已知 $\mathcal{F} = \{N(\mu, \sigma^2) : -\infty < \mu < \infty, \sigma > 0\}$ 为指数型分布族, 且 $\tilde{X} = (X_1, X_2, \dots, X_n)$ 的联合密度函数为

$$\begin{aligned} p(\tilde{x}; \mu, \sigma) &= \frac{1}{(2\pi\sigma^2)^{n/2}} \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \right\} \\ &= \frac{1}{(2\pi\sigma^2)^{n/2}} \exp \left\{ -\frac{n\mu^2}{2\sigma^2} \right\} \\ &\quad \cdot \exp \left\{ \left[\sum_{i=1}^n x_i \right] \left[\frac{\mu}{\sigma^2} \right] + \left[\sum_{i=1}^n x_i^2 \right] \left[-\frac{1}{2\sigma^2} \right] \right\}. \end{aligned}$$

对于 $-\infty < \mu < \infty$, $\sigma > 0$, 注意到 $(\mu/\sigma^2, -1/(2\sigma^2))$ 的值域有非空的内部, 故 $(\sum_{i=1}^n X_i, \sum_{i=1}^n X_i^2)$ 是充分完备统计量.

而它的一一变换 (\bar{X}, S^2) 是这个统计量的函数, 且分别是 μ 和 σ^2 的无偏估计. 故它们分别是 μ 和 σ^2 的UMVUE.

Example

考虑Gamma分布 $\Gamma(\alpha, \lambda)$, 设 $\alpha > 0$ 为已知的, $\lambda > 0$ 未知, 求 λ 的UMVUE.

解: 样本 $\tilde{X} = (X_1, \dots, X_n)$ 的联合密度函数为

$$p(\tilde{x}; \lambda) = \frac{\lambda^{n\alpha}}{(\Gamma(\alpha))^n} \prod_{i=1}^n x_i^{\alpha-1} \exp \left\{ -\lambda \sum_{i=1}^n x_i \right\} \\ \cdot I\{x_i > 0, i = 1, \dots, n\};$$

利用指数型分布族的性质可知, 当 α 已知时, $T = \sum_{i=1}^n X_i$ 是分布族 $\{\Gamma(\alpha, \lambda) : \lambda > 0\}$ 的充分完备统计量.

而由Gamma分布的可加性可得 $T \sim \Gamma(n\alpha, \lambda)$, 所以

$$E_{\lambda}T = \frac{n\alpha}{\lambda},$$

即

$$\lambda = \frac{n\alpha}{E_{\lambda}T}.$$

??????

§3.4 一致最小方差无偏估计

$$\begin{aligned} E_{\lambda} \left[\frac{1}{T} \right] &= \int_0^{\infty} \frac{1}{t} p(t; \lambda) dt = \frac{\lambda^{n\alpha}}{\Gamma(n\alpha)} \int_0^{\infty} t^{(n\alpha-1)-1} e^{-\lambda t} dt \\ &= \frac{\lambda \Gamma(n\alpha - 1)}{\Gamma(n\alpha)} = \frac{\lambda}{n\alpha - 1}. \end{aligned}$$

因此

$$E_{\lambda} \left[\frac{n\alpha - 1}{T} \right] = \lambda.$$

根据定理3.4.2,

$$\hat{\lambda} = \frac{n\alpha - 1}{\sum_{i=1}^n X_i} = \frac{n\alpha - 1}{n\bar{X}}$$

是 λ 的UMVUE. 当 $\alpha = 1$ 时, $(n - 1)/(n\bar{X})$ 为指数分布 $E(\lambda)$ 的参数 λ 的UMVUE.

另解: 我们要在 T 的函数 $h(T)$ 中找无偏估计, 即

$$E_{\lambda}h(T) = \frac{\lambda^{n\alpha}}{\Gamma(n\alpha)} \int_0^{+\infty} h(t)t^{n\alpha-1}e^{-\lambda t}dt = \lambda, \quad \forall \lambda > 0.$$

即

$$\frac{1}{\Gamma(n\alpha)} \int_0^{+\infty} h(t)t^{n\alpha-1}e^{-\lambda t}dt = \lambda^{-n\alpha+1}, \quad \forall \lambda > 0.$$

所以

$$\begin{aligned} & \frac{1}{\Gamma(n\alpha)} \int_0^{+\infty} h(t)t^{n\alpha-1}e^{-\lambda t}dt \\ &= \frac{1}{\Gamma(n\alpha-1)} \int_0^{+\infty} t^{(n\alpha-1)-1}e^{-\lambda t}dt \\ &= \frac{n\alpha-1}{\Gamma(n\alpha)} \int_0^{+\infty} t^{(n\alpha-1)-1}e^{-\lambda t}dt, \quad \forall \lambda > 0. \end{aligned}$$

从而

$$\frac{1}{\Gamma(n\alpha)} \int_0^\infty \left((h(t) - \frac{n\alpha - 1}{t}) t^{n\alpha-1} \right) e^{-\lambda t} dt = 0, \quad \forall \lambda > 0.$$

由Laplace变换的唯一性知

$$h(t) = \frac{n\alpha - 1}{t}, \quad a.e., \quad \forall t > 0.$$

故

$$\hat{\lambda} = \frac{n\alpha - 1}{\sum_{i=1}^n X_i} = \frac{n\alpha - 1}{n\bar{X}}$$

是 λ 的UMVUE.

Example

总体 X 的分布来自指数分布族 $\mathcal{F} = \{E(\lambda), \lambda > 0\}$, 其分布函数为 $F(x; \lambda)$, 概率密度函数为 $p(x; \lambda)$. 设 $\tilde{X} = \{X_1, X_2, \dots, X_n\}$ 是来自该总体的简单随机样本. 对某 $x_0 > 0$, 求 $F(x_0; \lambda)$ 和 $p(x_0; \lambda)$ 的UMVUE.

解: 由于 X 的概率密度函数为 $p(x; \lambda) = \lambda \cdot \exp\{-\lambda x\}I\{x > 0\}$, 故为指数型分布族. 此时样本 \tilde{X} 的联合概率密度函数为

$$p(\tilde{x}; \lambda) = \lambda^n \cdot \exp\left\{-\lambda \sum_{i=1}^n x_i\right\}I\{x_i > 0, i = 1, 2, \dots, n\},$$

其中 $Q(\lambda) = -\lambda$, 其值域为 $(-\infty, 0)$ 具有非空的内部, 故由指数型分布族的性质可知, $T = \sum_{i=1}^n X_i$ 是该分布族的充分完备统计量.

对于某 $x_0 > 0$, 记 $\varphi(\tilde{X}) = I\{X_1 < x_0\}$, 则

$$E(\varphi(\tilde{X})) = P(X_1 < x_0) = F(x_0; \lambda),$$

即 $\varphi(\tilde{X})$ 为 $F(x_0; \lambda)$ 的一个无偏估计. 那么由LS定理可知, $F(x_0; \lambda)$ 的UMVUE为 $E(\varphi(\tilde{X})|T)$.

注意到对于 $t > 0$, $E(\varphi(\tilde{X})|T = t) = P(X_1 < x_0|T = t)$ 即为在 $\{T = t\}$ 的条件下, X_1 的条件分布函数在 x_0 处的函数值 $F_{X_1|T}(x_0|t)$. 当 $0 < x_0 \leq t$ 时,

$$\begin{aligned} P(X_1 < x_0|T = t) &= P\left(\frac{X_1}{T} < \frac{x_0}{t}|T = t\right) \\ &= P\left(\frac{X_1}{X_1 + \sum_{i=2}^n X_i} < \frac{x_0}{t}|T = t\right). \end{aligned}$$

而 $X_1 \sim \Gamma(1, \lambda)$, $\sum_{i=2}^n X_i \sim \Gamma(n-1, \lambda)$ 且与 X_1 独立,

故 $\frac{X_1}{T} = \frac{X_1}{X_1 + \sum_{i=2}^n X_i} \sim \beta(1, n-1)$, 其分布与参数 λ 无关. 而 T 为参数 λ 的充分统计量, 且为完备统计量, 根据 Basu 定理, 知 $\frac{X_1}{T}$ 与 T 独立.

因此

$$\begin{aligned} \mathbf{P}(X_1 < x_0 | T = t) &= \mathbf{P}\left(\frac{X_1}{T} < \frac{x_0}{t} | T = t\right) = \mathbf{P}\left(\frac{X_1}{T} < \frac{x_0}{t}\right) \\ &= \int_0^{\frac{x_0}{t}} \frac{\Gamma(1 + (n-1))}{\Gamma(1)\Gamma(n-1)} y^{1-1} (1-y)^{(n-1)-1} dy \\ &= \int_0^{\frac{x_0}{t}} (n-1)(1-y)^{n-2} dy = 1 - \left(1 - \frac{x_0}{t}\right)^{n-1}. \end{aligned}$$

当 $x_0 > t$ 时, $\mathbf{P}(X_1 < x_0 | T = t) = 1$.

所以 $F(x_0; \lambda)$ 的UMVUE为

$$\widehat{F(x_0; \lambda)} = 1 - \left(1 - \frac{x_0}{T}\right)^{n-1} I\{0 < x_0 \leq T\}.$$

对于 $t > 0$, 记 $p(x|t) := p_{X_1|T}(x|t)$ 为在 $\{T = t\}$ 的条件下, X_1 的条件概率密度函数. 并记 $p(x_0, t)$ 为 X_1 与 T 的联合密度函数. 则

$$\begin{aligned} E(p(x_0|T)) &= \int_0^{\infty} p(x_0|t)p_T(t)dt \\ &= \int_0^{\infty} \frac{p(x_0, t)}{p_T(t)} \cdot p_T(t)dt = p_{X_1}(x_0; \lambda). \end{aligned}$$

即 $p(x_0|T)$ 为 $p(x_0; \lambda)$ 的无偏估计, 注意到它还是充分完备统计量 T 的函数, 因此 $p(x_0|T)$ 为 $p(x_0; \lambda)$ 的UMVUE. 根据条件密度函数与条件分布函数的关系, 可知

$$\widehat{p(x_0; \lambda)} = p(x_0|T) = (n-1)\left(1 - \frac{x_0}{T}\right)^{n-2} \cdot \frac{1}{T} I\{0 < x_0 \leq T\}.$$